

# LGN5830 - Biometria de Marcadores Genéticos

## Tópico 2: Verossimilhança

Antonio Augusto Franco Garcia

<http://about.me/augusto.garcia>  
[augusto.garcia@usp.br](mailto:augusto.garcia@usp.br)

Departamento de Genética  
ESALQ/USP  
2015



UNIVERSIDADE DE SÃO PAULO  
DEPARTAMENTO DE GENÉTICA  
FRAC-CABA, SP, BRAZIL



## Conteúdo

- 1 Distribuição de Probabilidades
  - Regras Básicas
  - Distribuição Binomial
  - Distribuição Normal
- 2 Esperança Matemática
  - Alguns Fundamentos
- 3 Verossimilhança
  - Introdução
  - Definição
  - Estimador de Máxima Verossimilhança
- 4 Referências

# Conteúdo

## 1 Distribuição de Probabilidades

- Regras Básicas
- Distribuição Binomial
- Distribuição Normal

## 2 Esperança Matemática

- Alguns Fundamentos

## 3 Verossimilhança

- Introdução
- Definição
- Estimador de Máxima Verossimilhança

## 4 Referências

## Conteúdo

### 1 Distribuição de Probabilidades

- Regras Básicas
- Distribuição Binomial
- Distribuição Normal

### 2 Esperança Matemática

- Alguns Fundamentos

### 3 Verossimilhança

- Introdução
- Definição
- Estimador de Máxima Verossimilhança

### 4 Referências

## Conteúdo

- 1 Distribuição de Probabilidades
  - Regras Básicas
  - Distribuição Binomial
  - Distribuição Normal
- 2 Esperança Matemática
  - Alguns Fundamentos
- 3 Verossimilhança
  - Introdução
  - Definição
  - Estimador de Máxima Verossimilhança
- 4 Referências

## 1 Distribuição de Probabilidades

- Regras Básicas
- Distribuição Binomial
- Distribuição Normal

## 2 Esperança Matemática

- Alguns Fundamentos

### 3 Verossimilhança

- Introdução
- Definição
- Estimador de Máxima Verossimilhança

#### 4 Referências

### Classical PROBABILITY:

BASED ON GAMBLING IDEAS, THE FUNDAMENTAL ASSUMPTION IS THAT THE GAME IS FAIR AND ALL ELEMENTARY OUTCOMES HAVE THE SAME PROBABILITY.



WHEN AN EXPERIMENT CAN BE REPEATED  
THEN AN EVENT'S PROBABILITY IS THE  
PROPORTION OF TIMES THE EVENT  
OCCURS IN THE LONG RUN.



**Personal** PROBABILITY: MOST OF LIFE'S EVENTS ARE NOT REPEATABLE. PERSONAL PROBABILITY IS AN INDIVIDUAL'S PERSONAL ASSESSMENT OF AN OUTCOME'S LIKELIHOOD. IF A GAMBLER BELIEVES THAT A HORSE HAS MORE THAN A 50% CHANCE OF WINNING, HE'LL TAKE AN EVEN BET ON THAT HORSE.



AN OBJECTIVIST USES EITHER THE CLASSICAL OR FREQUENCY DEFINITION OF PROBABILITY. A SUBJECTIVIST OR BAYESIAN APPLIES FORMAL LAWS OF CHANCE TO HIS OWN, OR YOUR, PERSONAL PROBABILITIES.

HOW DO YOU KNOW THE  
ELEMENTARY OUTCOMES  
ARE EQUALLY LIKELY  
WITHOUT ROLLING THE  
DICE A BILLION TIMES?

WANN  
BET?



## Regras

- Adição

$$P(A \text{ ou } B) = P(A) + P(B) - P(A \text{ e } B)$$

- Adição (eventos mutuamente exclusivos)

$$P(A \text{ ou } B) = P(A) + P(B)$$

- Subtração

$$P(A) = 1 - P(\text{não } A)$$

- Multiplicação

$$P(A \text{ e } B) = P(A) \times P(B|A)$$

- Multiplicação (A e B independentes)

$$P(A \text{ e } B) = P(A) \times P(B)$$

- Notação:  $P(A \text{ e } B) = P(A \cap B) = P(A, B)$



# Regras

- Adição

$$P(A \text{ ou } B) = P(A) + P(B) - P(A \text{ e } B)$$

- Adição (eventos mutuamente exclusivos)

$$P(A \text{ ou } B) = P(A) + P(B)$$

- Subtração

$$P(A) = 1 - P(\text{não } A)$$

- Multiplicação

$$P(A \text{ e } B) = P(A) \times P(B|A)$$

- Multiplicação (A e B independentes)

$$P(A \text{ e } B) = P(A) \times P(B)$$

- Notação:  $P(A \text{ e } B) = P(A \cap B) = P(A, B)$

## Regras

- Adição

$$P(A \text{ ou } B) = P(A) + P(B) - P(A \text{ e } B)$$

- Adição (eventos mutuamente exclusivos)

$$P(A \text{ ou } B) = P(A) + P(B)$$

- Subtração

$$P(A) = 1 - P(\text{não } A)$$

- Multiplicação

$$P(A \text{ e } B) = P(A) \times P(B|A)$$

- Multiplicação (A e B independentes)

$$P(A \text{ e } B) = P(A) \times P(B)$$

- Notação:  $P(A \text{ e } B) = P(A \cap B) = P(A, B)$

## Regras

- Adição

$$P(A \text{ ou } B) = P(A) + P(B) - P(A \text{ e } B)$$

- Adição (eventos mutuamente exclusivos)

$$P(A \text{ ou } B) = P(A) + P(B)$$

- Subtração

$$P(A) = 1 - P(\text{não } A)$$

- Multiplicação

$$P(A \text{ e } B) = P(A) \times P(B|A)$$

- Multiplicação (A e B independentes)

$$P(A \text{ e } B) = P(A) \times P(B)$$

- Notação:  $P(A \text{ e } B) = P(A \cap B) = P(A, B)$

## Regras

- Adição

$$P(A \text{ ou } B) = P(A) + P(B) - P(A \text{ e } B)$$

- Adição (eventos mutuamente exclusivos)

$$P(A \text{ ou } B) = P(A) + P(B)$$

- Subtração

$$P(A) = 1 - P(\text{não } A)$$

- Multiplicação

$$P(A \text{ e } B) = P(A) \times P(B|A)$$

- Multiplicação (A e B independentes)

$$P(A \text{ e } B) = P(A) \times P(B)$$

- Notação:  $P(A \text{ e } B) = P(A \cap B) = P(A, B)$

## Regras

- Adição

$$P(A \text{ ou } B) = P(A) + P(B) - P(A \text{ e } B)$$

- Adição (eventos mutuamente exclusivos)

$$P(A \text{ ou } B) = P(A) + P(B)$$

- Subtração

$$P(A) = 1 - P(\text{não } A)$$

- Multiplicação

$$P(A \text{ e } B) = P(A) \times P(B|A)$$

- Multiplicação (A e B independentes)

$$P(A \text{ e } B) = P(A) \times P(B)$$

- Notação:  $P(A \text{ e } B) = P(A \cap B) = P(A, B)$

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Se eu jogar os dois dados simultaneamente, qual é a probabilidade de obter soma 3?
  - # resultados possíveis:  $6 \times 6 = 36$
  - # resultados com soma 3: 2 ( $\{1, 2\}, \{2, 1\}$ )
  - Resp:  $P(\text{soma } 3) = 2/36$

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Se eu jogar os dois dados simultaneamente, qual é a probabilidade de obter soma 3?
  - # resultados possíveis:  $6 \times 6 = 36$
  - # resultados com soma 3: 2 ( $\{1, 2\}, \{2, 1\}$ )
  - Resp:  $P(\text{soma } 3) = 2/36$

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Se eu jogar os dois dados simultaneamente, qual é a probabilidade de obter soma 3?
  - # resultados possíveis:  $6 \times 6 = 36$
  - # resultados com soma 3: 2 ( $\{1, 2\}, \{2, 1\}$ )
  - Resp:  $P(\text{soma } 3) = 2/36$



## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Se eu jogar os dois dados simultaneamente, qual é a probabilidade de obter soma 3?
  - # resultados possíveis:  $6 \times 6 = 36$
  - # resultados com soma 3: 2 ( $\{1, 2\}, \{2, 1\}$ )
  - Resp:  $P(\text{soma } 3) = 2/36$

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Suponha agora que um dos dois dados foi jogado antes, e o resultado foi 1
- Qual a probabilidade de obter soma 3?

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Suponha agora que um dos dois dados foi jogado antes, e o resultado foi 1
- Qual a probabilidade de obter soma 3?
  - # resultados possíveis: 6
  - # resultados com soma 3: 1 ( $\{1, 2\}$ )
  - Resp:  $P(\text{soma } 3 | \text{valor } 1 \text{ em um dos dados}) = 1/6$

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Suponha agora que um dos dois dados foi jogado antes, e o resultado foi 1
- Qual a probabilidade de obter soma 3?
  - # resultados possíveis: 6
  - # resultados com soma 3: 1 ( $\{1, 2\}$ )
  - Resp:  $P(\text{soma } 3 | \text{valor } 1 \text{ em um dos dados}) = 1/6$

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Suponha agora que um dos dois dados foi jogado antes, e o resultado foi 1
- Qual a probabilidade de obter soma 3?
  - # resultados possíveis: 6
  - # resultados com soma 3: 1 ( $\{1, 2\}$ )
  - Resp:  $P(\text{soma } 3 | \text{valor } 1 \text{ em um dos dados}) = 1/6$

## Probabilidade Condicional

### *Dois dados com cores diferentes*

- Suponha agora que um dos dois dados foi jogado antes, e o resultado foi 1
- Qual a probabilidade de obter soma 3?
  - # resultados possíveis: 6
  - # resultados com soma 3: 1 ( $\{1, 2\}$ )
  - Resp:  $P(\text{soma } 3 | \text{valor } 1 \text{ em um dos dados}) = 1/6$

## Probabilidade Condicional

$$P(A|B)$$

$$P(A|B) = \frac{P(A, B)}{P(B)}$$

### Atenção

- Note a relação entre probab. condicional e a regra da multiplicação
- O que significam  $P(A|B) = 1$  e  $P(A|B) = 0$ ?
- Eventos independentes:  $P(A, B) = P(A) \times P(B)$

### Exemplo anterior

$$P(A|B) = \frac{P(A, B)}{P(B)} = \frac{\frac{1}{36}}{\frac{1}{6}} = \frac{1}{6}$$

## Probabilidade Condicional

$$P(A|B)$$

$$P(A|B) = \frac{P(A, B)}{P(B)}$$

### Atenção

- Note a relação entre probab. condicional e a regra da multiplicação
- O que significam  $P(A|B) = 1$  e  $P(A|B) = 0$ ?
- Eventos independentes:  $P(A, B) = P(A) \times P(B)$

### Exemplo anterior

$$P(A|B) = \frac{P(A, B)}{P(B)} = \frac{\frac{1}{36}}{\frac{1}{6}} = \frac{1}{6}$$



## Probabilidade Condicional

$$P(A|B)$$

$$P(A|B) = \frac{P(A, B)}{P(B)}$$

### Atenção

- Note a relação entre probab. condicional e a regra da multiplicação
- O que significam  $P(A|B) = 1$  e  $P(A|B) = 0$ ?
- Eventos independentes:  $P(A, B) = P(A) \times P(B)$

### Exemplo anterior

$$P(A|B) = \frac{P(A, B)}{P(B)} = \frac{\frac{1}{36}}{\frac{1}{6}} = \frac{1}{6}$$

## Eventos independentes

### Moeda “honesta”

- Qual a probabilidade de obter uma sequência de 4 caras?

● Resp:  $\left(\frac{1}{2}\right)^4$

## Eventos independentes

### Moeda "honesta"

- Qual a probabilidade de obter uma sequência de 4 caras?
- Resp:  $\left(\frac{1}{2}\right)^4$

# Eventos independentes

## Moeda “honesta”



Qual a probabilidade de obter uma sequência de 4 caras?

# Eventos independentes

## INDEPENDENCE and the special multiplication rule.

TWO EVENTS *E* AND *F* ARE *INDEPENDENT* OF EACH OTHER IF THE OCCURRENCE OF ONE HAS *NO INFLUENCE* ON THE PROBABILITY OF THE OTHER. FOR INSTANCE, THE ROLL OF ONE DIE HAS NO EFFECT ON THE ROLL OF ANOTHER (UNLESS THEY'RE GLUED TOGETHER, MAGNETIC, ETC!).



# Um caso simples

## Doença, Genótipo

	<i>mm</i>	<i>Mm</i>	<i>MM</i>	
<i>R</i>	0.10	0.21	0.47	0.78
<i>S</i>	0.05	0.09	0.08	0.22
	0.15	0.30	0.55	1

- $P(D = R) = 0.78$
- $P(G = Mm) = 0.30$
- $P(D = R|G = MM) = \frac{P(D=R, G=MM)}{P(G=MM)} = \frac{0.47}{0.55} = 0.85$
- $P(D = R, G = MM) = P(D = R) P(G = MM|D = R) = 0.78 \times \frac{0.47}{0.78} = 0.47$
- Note que  $P(D = R).P(G = MM) = 0.78 \times 0.55 = 0.429$

# Um caso simples

## Doença, Genótipo

	<i>mm</i>	<i>Mm</i>	<i>MM</i>	
<i>R</i>	0.10	0.21	0.47	0.78
<i>S</i>	0.05	0.09	0.08	0.22
	0.15	0.30	0.55	1

- $P(D = R) = 0.78$
- $P(G = Mm) = 0.30$
- $P(D = R|G = MM) = \frac{P(D=R, G=MM)}{P(G=MM)} = \frac{0.47}{0.55} = 0.85$
- $P(D = R, G = MM) = P(D = R) P(G = MM|D = R) = 0.78 \times \frac{0.47}{0.78} = 0.47$
- Note que  $P(D = R).P(G = MM) = 0.78 \times 0.55 = 0.429$

## Um caso simples

### Doença, Genótipo

	<i>mm</i>	<i>Mm</i>	<i>MM</i>	
<i>R</i>	0.10	0.21	0.47	0.78
<i>S</i>	0.05	0.09	0.08	0.22
	0.15	0.30	0.55	1

- $P(D = R) = 0.78$
- $P(G = Mm) = 0.30$
- $P(D = R|G = MM) = \frac{P(D=R, G=MM)}{P(G=MM)} = \frac{0.47}{0.55} = 0.85$
- $P(D = R, G = MM) = P(D = R) P(G = MM|D = R) = 0.78 \times \frac{0.47}{0.78} = 0.47$
- Note que  $P(D = R).P(G = MM) = 0.78 \times 0.55 = 0.429$



## Um caso simples

### Doença, Genótipo

	$mm$	$Mm$	$MM$	
$R$	0.10	0.21	0.47	0.78
$S$	0.05	0.09	0.08	0.22
	0.15	0.30	0.55	1

- $P(D = R) = 0.78$
- $P(G = Mm) = 0.30$
- $P(D = R|G = MM) = \frac{P(D=R, G=MM)}{P(G=MM)} = \frac{0.47}{0.55} = 0.85$
- $P(D = R, G = MM) = P(D = R) P(G = MM|D = R) = 0.78 \times \frac{0.47}{0.78} = 0.47$
- Note que  $P(D = R) \cdot P(G = MM) = 0.78 \times 0.55 = 0.429$

## Um caso simples

### Doença, Genótipo

	<i>mm</i>	<i>Mm</i>	<i>MM</i>	
<i>R</i>	0.10	0.21	0.47	0.78
<i>S</i>	0.05	0.09	0.08	0.22
	0.15	0.30	0.55	1

- $P(D = R) = 0.78$
- $P(G = Mm) = 0.30$
- $P(D = R|G = MM) = \frac{P(D=R, G=MM)}{P(G=MM)} = \frac{0.47}{0.55} = 0.85$
- $P(D = R, G = MM) = P(D = R) P(G = MM|D = R) = 0.78 \times \frac{0.47}{0.78} = 0.47$
- Note que  $P(D = R).P(G = MM) = 0.78 \times 0.55 = 0.429$

# Teorema de Bayes

Thomas Bayes, 1701–1761

$$P(A|B) = \frac{P(A) P(B|A)}{P(B)}$$

- $P(A)$ : “priori”
- $P(A|B)$ : “posteriori”
- $P(B|A)/P(B)$ : suporte que  $B$  fornece para  $A$

# Conteúdo

## 1 Distribuição de Probabilidades

- Regras Básicas
- **Distribuição Binomial**
- Distribuição Normal

## 2 Esperança Matemática

- Alguns Fundamentos

## 3 Verossimilhança

- Introdução
- Definição
- Estimador de Máxima Verossimilhança

## 4 Referências

# Variável Discreta

## Exemplo - Distribuição Binomial

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, proveniente de um retrocruzamento.
- Neste caso, temos teoricamente 50% dos indivíduos com este genótipo ( $\theta = 1/2$ )
- Qual a probabilidade de observarmos  $x$  genótipos  $Aa$  numa amostra de 4 indivíduos ( $n = 4$ )?

$$P(x) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$

- Note que estamos assumindo que os eventos são independentes!

# Variável Discreta

## Exemplo - Distribuição Binomial

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, proveniente de um retrocruzamento.
- Neste caso, temos teoricamente 50% dos indivíduos com este genótipo ( $\theta = 1/2$ )
- Qual a probabilidade de observarmos  $x$  genótipos  $Aa$  numa amostra de 4 indivíduos ( $n = 4$ )?
  - $$P(x) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$
- Note que estamos assumindo que os eventos são independentes!

# Variável Discreta

## Exemplo - Distribuição Binomial

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, proveniente de um retrocruzamento.
- Neste caso, temos teoricamente 50% dos indivíduos com este genótipo ( $\theta = 1/2$ )
- Qual a probabilidade de observarmos  $x$  genótipos  $Aa$  numa amostra de 4 indivíduos ( $n = 4$ )?

$$P(x) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$

- Note que estamos assumindo que os eventos são independentes!

# Variável Discreta

## Exemplo - Distribuição Binomial

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, proveniente de um retrocruzamento.
- Neste caso, temos teoricamente 50% dos indivíduos com este genótipo ( $\theta = 1/2$ )
- Qual a probabilidade de observarmos  $x$  genótipos  $Aa$  numa amostra de 4 indivíduos ( $n = 4$ )?

$$P(x) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$

- Note que estamos assumindo que os eventos são independentes!



# Variável Discreta


## Exemplo - Distribuição Binomial

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, proveniente de um retrocruzamento.
- Neste caso, temos teoricamente 50% dos indivíduos com este genótipo ( $\theta = 1/2$ )
- Qual a probabilidade de observarmos  $x$  genótipos  $Aa$  numa amostra de 4 indivíduos ( $n = 4$ )?
  - $$P(x) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$
- Note que estamos assumindo que os eventos são **independentes!**

## Distribuição Binomial

# Distribuição Binomial

## Exemplo



## Distribuição Binomial

### Exemplo


- Qual a probabilidade de observarmos 3 genótipos  $Aa$  ( $x = 3$ ) numa amostra de 4 indivíduos ( $n = 4$ )?

$$P(3) = \binom{4}{3} (1/2)^3 [1 - (1/2)]^{(4-3)} = 1/4$$

# Distribuição Binomial

## Exemplo

- Qual a probabilidade de observarmos 3 genótipos  $Aa$  ( $x = 3$ ) numa amostra de 4 indivíduos ( $n = 4$ )?
  - $P(3) = \binom{4}{3} (1/2)^3 [1 - (1/2)]^{(4-3)} = 1/4$




## Distribuição Binomial

# Distribuição Binomial

## Outras distribuições

- E se  $\theta$  tiver outros valores?



# Conteúdo

## 1 Distribuição de Probabilidades

- Regras Básicas
- Distribuição Binomial
- Distribuição Normal

## 2 Esperança Matemática

- Alguns Fundamentos

## 3 Verossimilhança

- Introdução
- Definição
- Estimador de Máxima Verossimilhança

## 4 Referências

# Distribuição Normal

- Grande parte das variáveis (caracteres) estudados na Genética

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

*Exemplo: teor de açúcar numa população de cana-de-açúcar*

- Concentração em torno da média, dispersão, indivíduos raros, etc


## Distribuição Normal

# Distribuição Normal

- Grande parte das variáveis (caracteres) estudados na Genética

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

*Exemplo: teor de açúcar numa população de cana-de-açúcar*



- Concentração em torno da média, dispersão, indivíduos raros, etc




## Distribuição Normal

# Distribuição Normal

- Grande parte das variáveis (caracteres) estudados na Genética

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$


*Exemplo: teor de açúcar numa população de cana-de-açúcar*



- Concentração em torno da média, dispersão, indivíduos raros, etc

# Densidade de Probabilidades

Qual a probab. de seleccionar ind. com Brix acima de 22?



## Modelo vs dados reais

- É óbvio que dados reais não estão “classificados”
- Várias técnicas são empregadas (histogramas, boxplots, ramo-e-folhas, etc)

*Brix, 200 valores*

## Modelo vs dados reais


- É óbvio que dados reais não estão “classificados”
- Várias técnicas são empregadas (histogramas, boxplots, ramo-e-folhas, etc

*Brix, 200 valores*

## Modelo vs dados reais





- É óbvio que dados reais não estão “classificados”
- Várias técnicas são empregadas (histogramas, boxplots, ramo-e-folhas, etc

*Brix, 200 valores*



# Exercício




Qual(is) conj. foram amostrado(s) em pop. com dist. normal?



## Distribuição Normal





## Exercício

*Todos eles! ( $n = 50$ )*



# Exercício

## Tamanho da amostra






Distribuição Normal

# História - Tycho Brahe

## Movimento de corpos celestiais



## Alguns Fundamentos

# Conteúdo

- 1 Distribuição de Probabilidades
  - Regras Básicas
  - Distribuição Binomial
  - Distribuição Normal
- 2 Esperança Matemática
  - Alguns Fundamentos
- 3 Verossimilhança
  - Introdução
  - Definição
  - Estimador de Máxima Verossimilhança
- 4 Referências

# Variável Discreta

## Retrocruzamento, com interesse em $Aa$

- Imagine um exp. hipotético **não realizado**, com 4 indivíduos

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- Resultados possíveis:

$Aa$	0	1	2	3	4
Probabilidade	$P(0)$	$P(1)$	$P(2)$	$P(3)$	$P(4)$

- Média esperada:

$$E(X) = \sum xP(x)$$

- Na distribuição binomial, demonstra-se que  $E(X) = np$
- No caso,  $E(X) = 4(1/2)$ , ou seja, 2 indivíduos com genótipo  $Aa$

# Variável Discreta

## Retrocruzamento, com interesse em $Aa$

- Imagine um exp. hipotético **não realizado**, com 4 indivíduos

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- Resultados possíveis:

$Aa$	0	1	2	3	4
Probabilidade	$P(0)$	$P(1)$	$P(2)$	$P(3)$	$P(4)$

- Média esperada:

$$E(X) = \sum xP(x)$$

- Na distribuição binomial, demonstra-se que  $E(X) = np$
- No caso,  $E(X) = 4(1/2)$ , ou seja, 2 indivíduos com genótipo  $Aa$

# Variável Discreta

## Retrocruzamento, com interesse em $Aa$

- Imagine um exp. hipotético **não realizado**, com 4 indivíduos

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- Resultados possíveis:

$Aa$	0	1	2	3	4
Probabilidade	$P(0)$	$P(1)$	$P(2)$	$P(3)$	$P(4)$

- Média esperada:

$$E(X) = \sum xP(x)$$

- Na distribuição binomial, demonstra-se que  $E(X) = np$
- No caso,  $E(X) = 4(1/2)$ , ou seja, 2 indivíduos com genótipo  $Aa$

# Variável Discreta

## Retrocruzamento, com interesse em $Aa$

- Imagine um exp. hipotético **não realizado**, com 4 indivíduos

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- Resultados possíveis:

$Aa$	0	1	2	3	4
Probabilidade	$P(0)$	$P(1)$	$P(2)$	$P(3)$	$P(4)$

- Média esperada:

$$E(X) = \sum xP(x)$$

- Na distribuição binomial, demonstra-se que  $E(X) = np$
- No caso,  $E(X) = 4(1/2)$ , ou seja, 2 indivíduos com genótipo  $Aa$

# Variável Discreta

## Retrocruzamento, com interesse em $Aa$

- Imagine um exp. hipotético **não realizado**, com 4 indivíduos

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- Resultados possíveis:

$Aa$	0	1	2	3	4
Probabilidade	$P(0)$	$P(1)$	$P(2)$	$P(3)$	$P(4)$

- Média esperada:


$$E(X) = \sum xP(x)$$

- Na distribuição binomial, demonstra-se que  $E(X) = np$
- No caso,  $E(X) = 4(1/2)$ , ou seja, 2 indivíduos com genótipo  $Aa$

## Alguns Fundamentos

# Variável Contínua

Brix de 200 indivíduos, cana-de-açúcar



- Qual a média desse experimento, com base no histograma?



## Variável Contínua

- Qual a média esperada para uma variável contínua?
- Esperança Matemática:

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

- Demonstra-se que, no caso da distribuição normal,  $E(X) = \mu$

## Variável Contínua

- Qual a média esperada para uma variável contínua?
- Esperança Matemática:

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

- Demonstra-se que, no caso da distribuição normal,  $E(X) = \mu$

## Variável Contínua

- Qual a média esperada para uma variável contínua?
- Esperança Matemática:

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

- Demonstra-se que, no caso da distribuição normal,  $E(X) = \mu$

# Conteúdo

- 1 Distribuição de Probabilidades
  - Regras Básicas
  - Distribuição Binomial
  - Distribuição Normal
- 2 Esperança Matemática
  - Alguns Fundamentos
- 3 Verossimilhança
  - **Introdução**
  - Definição
  - Estimador de Máxima Verossimilhança
- 4 Referências

# Alguns conceitos

## Experimento

- Conjunto de dados
- Informações sobre como esses dados foram coletados

## Inferência estatística

- Desejamos explicitar o modelo que deu origem aos dados
- Usualmente, o modelo envolve um ou mais parâmetros desconhecidos
- Os parâmetros devem ser estimados a partir dos dados

## Alguns conceitos

### Experimento

- Conjunto de dados
- Informações sobre como esses dados foram coletados

### Inferência estatística

- Desejamos explicitar o **modelo** que deu origem aos dados
- Usualmente, o modelo envolve um ou mais parâmetros desconhecidos
- Os parâmetros devem ser **estimados** a partir dos dados

# Alguns conceitos

## Experimento

- Conjunto de dados
- Informações sobre como esses dados foram coletados

## Inferência estatística

- Desejamos explicitar o **modelo** que deu origem aos dados
- Usualmente, o modelo envolve um ou mais parâmetros desconhecidos
- Os parâmetros devem ser **estimados** a partir dos dados

# Alguns conceitos

## Experimento

- Conjunto de dados
- Informações sobre como esses dados foram coletados

## Inferência estatística

- Desejamos explicitar o **modelo** que deu origem aos dados
- Usualmente, o modelo envolve um ou mais parâmetros desconhecidos
- Os parâmetros devem ser **estimados** a partir dos dados



# Método da Verossimilhança

- Suponha que um modelo probabilístico tenha sido formulado para um experimento
- Imagine que esse modelo envolva um parâmetro  $\theta$
- Desejamos usar os dados para estimar  $\theta$
- Formalmente, desejamos determinar quais são os possíveis valores de  $\theta$  mais plausíveis (**prováveis**, **verossímeis**), à luz das observações

# Método da Verossimilhança

- Suponha que um modelo probabilístico tenha sido formulado para um experimento
- Imagine que esse modelo envolva um parâmetro  $\theta$
- Desejamos usar os dados para estimar  $\theta$
- Formalmente, desejamos determinar quais são os possíveis valores de  $\theta$  mais plausíveis (prováveis, verossímeis), à luz das observações

# Método da Verossimilhança

- Suponha que um modelo probabilístico tenha sido formulado para um experimento
- Imagine que esse modelo envolva um parâmetro  $\theta$
- Desejamos usar os dados para estimar  $\theta$
- Formalmente, desejamos determinar quais são os possíveis valores de  $\theta$  mais plausíveis (prováveis, verossímeis), à luz das observações

# Método da Verossimilhança

- Suponha que um modelo probabilístico tenha sido formulado para um experimento
- Imagine que esse modelo envolva um parâmetro  $\theta$
- Desejamos usar os dados para estimar  $\theta$
- Formalmente, desejamos determinar quais são os possíveis valores de  $\theta$  mais plausíveis (**prováveis**, **verossímeis**), à luz das observações

# Método da Verossimilhança

## Exemplo

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, com 2 alelos para esse loco.
- Desejamos estimar essa proporção.
- Para tanto, selecionamos aleatoriamente  $n$  indivíduos e verificamos seu genótipo.
- Após o experimento, notamos que  $x$  deles são  $Aa$
- A probabilidade de observarmos esse evento  $E$  é  $P(E; \theta) = \text{probab. de } x, \text{ de um total de } n \text{ indivíduos, possuírem o genótipo } Aa$

$$P(E; \theta) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$

## Método da Verossimilhança

### Exemplo

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, com 2 alelos para esse loco.
- Desejamos estimar essa proporção.
- Para tanto, selecionamos aleatoriamente  $n$  indivíduos e verificamos seu genótipo.
- Após o experimento, notamos que  $x$  deles são  $Aa$
- A probabilidade de observarmos esse evento  $E$  é  $P(E; \theta) = \text{probab. de } x, \text{ de um total de } n \text{ indivíduos, possuírem o genótipo } Aa$

$$P(E; \theta) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$

# Método da Verossimilhança

## Exemplo

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, com 2 alelos para esse loco.
- Desejamos estimar essa proporção.
- Para tanto, selecionamos aleatoriamente  $n$  indivíduos e verificamos seu genótipo.
- Após o experimento, notamos que  $x$  deles são  $Aa$
- A probabilidade de observarmos esse evento  $E$  é  $P(E; \theta) = \text{probab. de } x, \text{ de um total de } n \text{ indivíduos, possuírem o genótipo } Aa$

$$P(E; \theta) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$

# Método da Verossimilhança

## Exemplo

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, com 2 alelos para esse loco.
- Desejamos estimar essa proporção.
- Para tanto, selecionamos aleatoriamente  $n$  indivíduos e verificamos seu genótipo.
- Após o experimento, notamos que  $x$  deles são  $Aa$
- A probabilidade de observarmos esse evento  $E$  é  $P(E; \theta) = \text{probab. de } x, \text{ de um total de } n \text{ indivíduos, possuírem o genótipo } Aa$

$$P(E; \theta) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$



# Método da Verossimilhança

## Exemplo

- Seja  $\theta$  a proporção de indivíduos  $Aa$  numa população grande e homogênea, com 2 alelos para esse loco.
- Desejamos estimar essa proporção.
- Para tanto, selecionamos aleatoriamente  $n$  indivíduos e verificamos seu genótipo.
- Após o experimento, notamos que  $x$  deles são  $Aa$
- A probabilidade de observarmos esse evento  $E$  é  $P(E; \theta) = \text{probab. de } x, \text{ de um total de } n \text{ indivíduos, possuírem o genótipo } Aa$

$$P(E; \theta) = \binom{n}{x} \theta^x (1 - \theta)^{(n-x)}$$

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

## Introdução

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

## Introdução

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

## Introdução

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?



## Introdução

# Método da Verossimilhança

## Exemplo

- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

## Introdução

# Método da Verossimilhança

## Exemplo

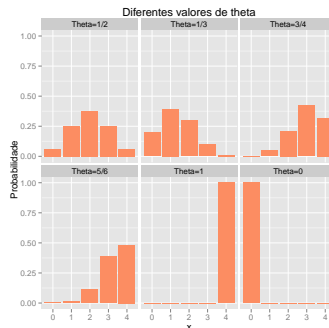
- Suponha que  $x = 3$  e  $n = 4$
- Note que, nesta situação,  $\theta$  não é conhecido
- $P(E; \theta) = \binom{4}{3} \theta^3 (1 - \theta)^{(4-3)}$ 
  - Se  $\theta = 1/2$ ,  $P(E; \theta) = 0.25$
  - Se  $\theta = 1/3$ ,  $P(E; \theta) = 0.10$
  - Se  $\theta = 3/4$ ,  $P(E; \theta) = 0.42$
  - Se  $\theta = 5/6$ ,  $P(E; \theta) = 0.39$
  - Se  $\theta = 1$ ,  $P(E; \theta) = 0$
- Qual valor de  $\theta$  é mais plausível?

## Introdução

# Verossimilhança

## Distribuições

- De qual distribuição os dados foram amostrados?



- Note que é mais fácil rejeitar do que aceitar

## Definição

# Conteúdo

## 1 Distribuição de Probabilidades

- Regras Básicas
- Distribuição Binomial
- Distribuição Normal

## 2 Esperança Matemática

- Alguns Fundamentos

## 3 Verossimilhança

- Introdução
- Definição
- Estimador de Máxima Verossimilhança

## 4 Referências

## Definição

# Método da Verossimilhança

## Definição

- A função de verossimilhança de  $\theta$  é **definida** como  $L(\theta) = c \cdot P(E; \theta)$
- Função de Verossimilhança: função densidade de probabilidade das observações, interpretada como uma função dos parâmetros que determinam a distribuição (Siegmund e Yakir, 2007)
- Edwards (1992): The *likelihood*  $L(H|R)$ , of the hypothesis  $H$  given data  $R$ , and a specific model, is proportional to  $P(R|H)$ , the constant of proportionality being arbitrary.

## Definição

## Método da Verossimilhança

### Definição

- A função de verossimilhança de  $\theta$  é **definida** como  $L(\theta) = c \cdot P(E; \theta)$
- Função de Verossimilhança: função densidade de probabilidade das observações, interpretada como uma função dos parâmetros que determinam a distribuição (Siegmund e Yakir, 2007)
- Edwards (1992): The *likelihood*  $L(H|R)$ , of the hypothesis  $H$  given data  $R$ , and a specific model, is proportional to  $P(R|H)$ , the constant of proportionality being arbitrary.

## Definição

## Método da Verossimilhança

### Definição

- A função de verossimilhança de  $\theta$  é **definida** como  $L(\theta) = c \cdot P(E; \theta)$
- Função de Verossimilhança: função densidade de probabilidade das observações, interpretada como uma função dos parâmetros que determinam a distribuição (Siegmund e Yakir, 2007)
- Edwards (1992): The *likelihood*  $L(H|R)$ , of the hypothesis  $H$  given data  $R$ , and a specific model, is proportional to  $P(R|H)$ , the constant of proportionality being arbitrary.

## Definição

# Método da Verossimilhança

## Definição

- Likelihood is the hypothetical probability that an event that has already occurred would yield a specific outcome. The concept differs from that of a probability in that a probability refers to the occurrence of future events, while a likelihood refers to past events with known outcomes.

(<http://mathworld.wolfram.com/Likelihood.html>)

- $L(\theta) \propto P(E; \theta)$
- $L(\theta) \propto \theta^x (1 - \theta)^{(n-x)}$  (no caso da dist. binomial)
- A constante  $c$ , por não depender dos parâmetros, normalmente é desconsiderada



## Definição

## Método da Verossimilhança

### Definição

- Likelihood is the hypothetical probability that an event that has already occurred would yield a specific outcome. The concept differs from that of a probability in that a probability refers to the occurrence of future events, while a likelihood refers to past events with known outcomes.

(<http://mathworld.wolfram.com/Likelihood.html>)

- $L(\theta) \propto P(E; \theta)$
- $L(\theta) \propto \theta^x (1 - \theta)^{(n-x)}$  (no caso da dist. binomial)
- A constante  $c$ , por não depender dos parâmetros, normalmente é desconsiderada

## Definição

# Verossimilhança

## Definição

- Sorensen e Gianola (2002): Sejam  $\mathbf{y}$  os dados observados, resultado de um processo estocástico caracterizado por um modelo com distribuição (densidade)  $p(\mathbf{y}|\theta)$
- A distribuição (densidade) das observações é portanto  $p(\mathbf{y}|\theta)$
- A verossimilhança  $L(\theta)$  ou  $L(\theta|\mathbf{y})$  é obtida com base em uma “inversão” deste conceito
- Por definição:  $L(\theta|\mathbf{y}) \propto p(\mathbf{y}|\theta)$

Definição

# Verossimilhança

## Definição

- Sorensen e Gianola (2002): Sejam  $\mathbf{y}$  os dados observados, resultado de um processo estocástico caracterizado por um modelo com distribuição (densidade)  $p(\mathbf{y}|\theta)$
- A distribuição (densidade) das observações é portanto  $p(\mathbf{y}|\theta)$
- A verossimilhança  $L(\theta)$  ou  $L(\theta|\mathbf{y})$  é obtida com base em uma “inversão” deste conceito
- Por definição:  $L(\theta|\mathbf{y}) \propto p(\mathbf{y}|\theta)$

## Definição

# Verossimilhança

## Definição

- Sorensen e Gianola (2002): Sejam  $\mathbf{y}$  os dados observados, resultado de um processo estocástico caracterizado por um modelo com distribuição (densidade)  $p(\mathbf{y}|\theta)$
- A distribuição (densidade) das observações é portanto  $p(\mathbf{y}|\theta)$
- A verossimilhança  $L(\theta)$  ou  $L(\theta|\mathbf{y})$  é obtida com base em uma “inversão” deste conceito
- Por definição:  $L(\theta|\mathbf{y}) \propto p(\mathbf{y}|\theta)$

## Definição

# Verossimilhança

## Definição

- Sorensen e Gianola (2002): Sejam  $\mathbf{y}$  os dados observados, resultado de um processo estocástico caracterizado por um modelo com distribuição (densidade)  $p(\mathbf{y}|\theta)$
- A distribuição (densidade) das observações é portanto  $p(\mathbf{y}|\theta)$
- A verossimilhança  $L(\theta)$  ou  $L(\theta|\mathbf{y})$  é obtida com base em uma “inversão” deste conceito
- Por definição:  $L(\theta|\mathbf{y}) \propto p(\mathbf{y}|\theta)$

## Definição

*Exemplo - genótipos Aa*

- Dados:  $\mathbf{y}_i$  ( $i = 1, \dots, n; n = 4$ )

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \prod_{i=1}^n p(\mathbf{y}_i|\theta)$

$$\underbrace{\theta, \theta, \dots, \theta}_x, \underbrace{(1 - \theta), (1 - \theta), \dots, (1 - \theta)}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$

- Verossimilhança:

$$L(\theta|\mathbf{y}) \propto \theta^x (1 - \theta)^{n-x}$$

## Definição

*Exemplo - genótipos Aa*

- Dados:  $\mathbf{y}_i$  ( $i = 1, \dots, n; n = 4$ )

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \prod_{i=1}^n p(\mathbf{y}_i|\theta)$

$$\underbrace{\theta, \theta, \dots, \theta}_x, \underbrace{(1 - \theta), (1 - \theta), \dots, (1 - \theta)}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$

- Verossimilhança:

$$L(\theta|\mathbf{y}) \propto \theta^x (1 - \theta)^{n-x}$$

## Definição

*Exemplo - genótipos Aa*

- Dados:  $\mathbf{y}_i$  ( $i = 1, \dots, n; n = 4$ )

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \prod_{i=1}^n p(\mathbf{y}_i|\theta)$

$$\underbrace{\theta, \theta, \dots, \theta}_x, \underbrace{(1 - \theta), (1 - \theta), \dots, (1 - \theta)}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$

- Verossimilhança:

$$L(\theta|\mathbf{y}) \propto \theta^x (1 - \theta)^{n-x}$$



## Definição

*Exemplo - genótipos Aa*

- Dados:  $\mathbf{y}_i$  ( $i = 1, \dots, n; n = 4$ )

$$\underbrace{1, 1, \dots, 1}_x, \underbrace{0, 0, \dots, 0}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \prod_{i=1}^n p(\mathbf{y}_i|\theta)$

$$\underbrace{\theta, \theta, \dots, \theta}_x, \underbrace{(1 - \theta), (1 - \theta), \dots, (1 - \theta)}_{n-x}$$

- $p(\mathbf{y}_i|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$

- Verossimilhança:

$$L(\theta|\mathbf{y}) \propto \theta^x (1 - \theta)^{n-x}$$

## Definição

*Peso de indivíduos amostrados numa pop.  $F_2$* 

- Um modelo possível:  $y_i \sim N(\mu, \sigma^2)$ , sendo  $\theta = (\mu, \sigma^2)$
- Verossimilhança:

$$L(\theta|\mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \mu)^2}{2\sigma^2}}$$

- Qual seria um modelo para estudar a variação do peso dos alunos da sala de aula?

## Definição

*Peso de indivíduos amostrados numa pop.  $F_2$* 

- Um modelo possível:  $y_i \sim N(\mu, \sigma^2)$ , sendo  $\theta = (\mu, \sigma^2)$
- Verossimilhança:

$$L(\theta|\mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(y_i - \mu)^2}{2\sigma^2}}$$

- Qual seria um modelo para estudar a variação do peso dos alunos da sala de aula?

## Definição

*Peso de indivíduos amostrados numa pop.  $F_2$* 

- Um modelo possível:  $y_i \sim N(\mu, \sigma^2)$ , sendo  $\theta = (\mu, \sigma^2)$
- Verossimilhança:

$$L(\theta|\mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(y_i - \mu)^2}{2\sigma^2}}$$

- Qual seria um modelo para estudar a variação do peso dos alunos da sala de aula?

# Conteúdo

- 1 Distribuição de Probabilidades
  - Regras Básicas
  - Distribuição Binomial
  - Distribuição Normal
- 2 Esperança Matemática
  - Alguns Fundamentos
- 3 Verossimilhança
  - Introdução
  - Definição
  - Estimador de Máxima Verossimilhança
- 4 Referências

# Método da Verossimilhança

- Para simplificar, é usual trabalharmos com o log de  $L(\theta)$
- Qual a razão?
- Notação:  $l(\theta) = \log_e L(\theta) = \log L(\theta)$
- $\frac{d l(\theta)}{d\theta}$  é dita **função score**
- $I(\theta) = -\frac{d^2 l(\theta)}{d\theta^2}$  é dita **função de informação de Fisher**

# Método da Verossimilhança

- Para simplificar, é usual trabalharmos com o log de  $L(\theta)$
- Qual a razão?

- Notação:  $l(\theta) = \log_e L(\theta) = \log L(\theta)$
- $\frac{d l(\theta)}{d\theta}$  é dita **função score**
- $I(\theta) = -\frac{d^2 l(\theta)}{d\theta^2}$  é dita **função de informação de Fisher**

# Método da Verossimilhança

- Para simplificar, é usual trabalharmos com o log de  $L(\theta)$
- Qual a razão?

**Atenção** Os pontos de máximo e mínimo não se alteram após o uso do logaritmo (função *monótona*)

- Notação:  $l(\theta) = \log_e L(\theta) = \log L(\theta)$
- $\frac{d l(\theta)}{d\theta}$  é dita **função score**
- $I(\theta) = -\frac{d^2 l(\theta)}{d\theta^2}$  é dita **função de informação de Fisher**



## Método da Verossimilhança

- Para simplificar, é usual trabalharmos com o log de  $L(\theta)$
- Qual a razão?

**Atenção** Os pontos de máximo e mínimo não se alteram após o uso do logaritmo (função *monótona*)

- Notação:  $l(\theta) = \log_e L(\theta) = \log L(\theta)$
- $\frac{d l(\theta)}{d\theta}$  é dita **função score**
- $I(\theta) = -\frac{d^2 l(\theta)}{d\theta^2}$  é dita **função de informação de Fisher**

# Método da Verossimilhança

- Para simplificar, é usual trabalharmos com o log de  $L(\theta)$
- Qual a razão?

**Atenção** Os pontos de máximo e mínimo não se alteram após o uso do logaritmo (função *monótona*)

- Notação:  $l(\theta) = \log_e L(\theta) = \log L(\theta)$
- $\frac{d l(\theta)}{d\theta}$  é dita **função score**
- $I(\theta) = -\frac{d^2 l(\theta)}{d\theta^2}$  é dita **função de informação de Fisher**

## *Estimador de Máxima Verossimilhança*

### *Exercício*

- 1 Qual a função de verossimilhança do exemplo anterior (binomial)?
- 2 Qual a função score?
- 3 Qual é o ponto de máximo de  $l(\theta)$ , dito  $\hat{\theta}$ ?

## *Estimador de Máxima Verossimilhança*

### *Exercício*

- 1 Qual a função de verossimilhança do exemplo anterior (binomial)?
- 2 Qual a função score?
- 3 Qual é o ponto de máximo de  $l(\theta)$ , dito  $\hat{\theta}$ ?

## *Estimador de Máxima Verossimilhança*

### *Exercício*

- 1 Qual a função de verossimilhança do exemplo anterior (binomial)?
- 2 Qual a função score?
- 3 Qual é o ponto de máximo de  $l(\theta)$ , dito  $\hat{\theta}$ ?

## Estimador de Máxima Verossimilhança



# Estimador de Máxima Verossimilhança

## Exercício

1  $L(\theta) \propto \theta^x (1 - \theta)^{(n-x)}$

2  $l(\theta) = x \log(\theta) + (n - x) \log(1 - \theta)$

3  $\hat{\theta} = \frac{x}{n}$



## MLE



- $\hat{\theta} = 3/4$  é o MLE de  $\theta$

## Estimador de Máxima Verossimilhança

# Estimador de Máxima Verossimilhança

## Exercício

- 1  $L(\theta) \propto \theta^x (1 - \theta)^{(n-x)}$
- 2  $l(\theta) = x \log(\theta) + (n - x) \log(1 - \theta)$
- 3  $\hat{\theta} = \frac{x}{n}$



## MLE

- $\hat{\theta} = 3/4$  é o MLE de  $\theta$

# MLE

## Distribuição Normal

$$1 \quad L(\theta|\mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(y_i - \mu)^2}{2\sigma^2}}$$

$$2 \quad \hat{\mu} = \frac{\sum_{i=1}^n y_i}{n} = \bar{\mathbf{y}}$$

$$3 \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n}$$

## MLE e Quadrados Mínimos

- Sob normalidade, os *MLE's* também são estimadores de quadrados mínimos



# MLE

## Distribuição Normal

$$1 \quad L(\theta|\mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(y_i - \mu)^2}{2\sigma^2}}$$

$$2 \quad \hat{\mu} = \frac{\sum_{i=1}^n y_i}{n} = \bar{\mathbf{y}}$$

$$3 \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n}$$

## MLE e Quadrados Mínimos

- Sob normalidade, os MLE's também são estimadores de quadrados mínimos

# MLE

## Distribuição Normal

$$1 \quad L(\theta|\mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(y_i - \mu)^2}{2\sigma^2}}$$

$$2 \quad \hat{\mu} = \frac{\sum_{i=1}^n y_i}{n} = \bar{\mathbf{y}}$$

$$3 \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n}$$

## MLE e Quadrados Mínimos

- Sob normalidade, os MLE's também são estimadores de quadrados mínimos

# MLE

## Distribuição Normal

$$1 \quad L(\theta|\mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(y_i - \mu)^2}{2\sigma^2}}$$

$$2 \quad \hat{\mu} = \frac{\sum_{i=1}^n y_i}{n} = \bar{\mathbf{y}}$$

$$3 \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n}$$

## MLE e Quadrados Mínimos

- Sob normalidade, os MLE's também são estimadores de quadrados mínimos

## Principais Referências



Gonick, L; Smith, W.

The Cartoon Guide to Statistics

*Editora Harper Perennial, 1993*



Kalbfleisch, J.G.

Probability and Statistical Inference

*Editora Springer-Verlag, 1985 Volume 1*



Edwards, A.W.F.

Likelihood (expanded edition)

*The John Hopkins University, 1992*

## Principais Referências



Sorensen, D.; Gianola, D.

Likelihood, Bayesian, and MCMC Methods in  
Quantitative Genetics

*Editora Springer-Verlag, 2002*



Koller, D.; Friedman, N.

Probabilistic Graphical Models: Principles and Techniques

*MIT Press, 2009*